

Apprentissage statistique

Vincent Lefieux



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Généralités

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Apprentissage supervisé ou non I

- ▶ Apprentissage **supervisé** :
Inférer (prédire) une fonction ou une relation à partir de **données d'apprentissage labellisées** (on parle aussi d'exemples étiquetés).
On distingue :
 - ▶ La **régression** : pour un label **quantitatif**.
 - ▶ La **classification supervisée** : pour un label **qualitatif**.
- ▶ Apprentissage **non-supervisé** :
Trouver une « structure » dans des **données non-labellisées** (ex : clustering, *dimension reduction*).
Même s'il est plus « subjectif » que l'apprentissage supervisé, il peut être utile comme étape de pré-traitement pour l'apprentissage supervisé.

Généralités

Apprentissage supervisé


Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé ou non II



The difference between supervised and unsupervised learning, illustrated by [@Ciaraioch](#)

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé I

	Covariables						Label
	X_1	X_2	X_3	...	X_{p-1}	X_p	Y
$i = 1$				...			
$i = 2$				...			
$i = 3$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$i = n - 1$				...			
$i = n$				...			

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé II

	Covariables						Label
	X_1	X_2	X_3	...	X_{p-1}	X_p	y
$i = 1$				...			
$i = 2$				...			
$i = 3$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$i = n - 1$				...			
$i = n$				...			

-Qualitatif : classification supervisée
-Quantitatif : régression

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé III

	Covariables						Label
	X_1	X_2	X_3	...	X_{p-1}	X_p	Y
$i = 1$				...			
$i = 2$				...			
$i = 3$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$i = n - 1$				...			
$i = n$				...			

$\Rightarrow \forall i \in \{1, \dots, n\} : y_i \approx \hat{f}(x_{i1}, \dots, x_{ip})$

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé IV

	Covariables						Label
	X_1	X_2	X_3	...	X_{p-1}	X_p	Y
$i = 1$				...			
$i = 2$				...			
$i = 3$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$i = n - 1$				...			
$i = n$				...			

$\Rightarrow \forall i \in \{1, \dots, n\} : y_i \approx \hat{f}(x_{i1}, \dots, x_{ip})$

$i = n + 1$				...		
-------------	---	---	---	-----	---	---

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé V

	Covariables						Label
	X_1	X_2	X_3	...	X_{p-1}	X_p	Y
$i = 1$				...			
$i = 2$				...			
$i = 3$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$i = n - 1$				...			
$i = n$				...			

$\Rightarrow \forall i \in \{1, \dots, n\} : y_i \approx \hat{f}(x_{i1}, \dots, x_{ip})$

$i = n + 1$				...			
-------------	--	--	--	-----	--	--	--

$\leftarrow y_{n+1}^{(p)} = \hat{f}(x_{n+1,1}, \dots, x_{n+1,p})$

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage supervisé VI

	Covariables						Label
	X_1	X_2	X_3	...	X_{p-1}	X_p	Y
$i = 1$				...			
$i = 2$				...			
$i = 3$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$i = n - 1$				...			
$i = n$				...			

$\Rightarrow \forall i \in \{1, \dots, n\} : y_i \approx \hat{f}(x_{i1}, \dots, x_{ip})$

$i = n + 1$				...			
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$

$\leftarrow y_{n+1}^{(p)} = \hat{f}(x_{n+1,1}, \dots, x_{n+1,p})$

Généralités

Apprentissage supervisé


Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Apprentissage non-supervisé



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

D'autres types d'apprentissage

- ▶ Apprentissage **par renforcement** :
Faire apprendre à un agent autonome les actions à prendre à partir d'expériences, de manière à optimiser une récompense quantitative au cours du temps.
- ▶ Apprentissage **par transfert** :
Transposer par analogie un apprentissage mené sur un problème similaire mais différent (avec du **fine tuning**).

Généralités

Apprentissage
supervisé


Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Une cartographie



Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Quelques méthodes d'apprentissage supervisé

- ▶ **Modèle linéaire généralisé** : régression linéaire, régression de Poisson, régression logistique.
- ▶ **Méthodes régularisés** : Ridge, Lasso, Elasticnet, Lars.
- ▶ **Méthodes bayésiennes**.
- ▶ **Méthodes splines** : régression spline, GAM.
- ▶ D'autres méthodes : analyse discriminante linéaire, PLS, méthodes à directions révélatrice (*index model*).
- ▶ **Méthodes de moyennage local** : plus proches voisins, noyau de lissage, CART.
- ▶ **Méthodes d'agrégation** : bagging (dont random forests), gradient boosting.
- ▶ **Méthodes à noyau** : SVM (et SVR).
- ▶ **Réseaux de neurones** : DNN, CNN, RNN.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Quelques méthodes d'apprentissage non-supervisé

- ▶ **Classification non supervisé** (*clustering*) : K-means, CAH, DBSCAN, modèles de mélange, auto-encodeurs, cartes de Kohonen (SOM : *Self Organizing Maps*).
- ▶ **Réduction de dimension** (*dimension reduction*) : ACP, AFC, ACM.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

- ▶ On peut distinguer **modélisation** et **prévision**, par exemple compression d'image vs. reconnaissance d'images.
- ▶ Un modèle s'appuie sur la **régularité** des phénomènes sous-jacents.
- ▶ La **prévision** consiste à **généraliser** un modèle.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Quelques enjeux en prévision

- ▶ Compromis entre la **qualité de la prévision** et l'**interprétabilité** (notion de « boîte noire »).
- ▶ Privilégier des **modèles parcimonieux** (« sparse ») qui éviteront le **sur-apprentissage**.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Le fléau de la dimension I

- ▶ En grande dimension, il est nécessaire de disposer de volumes de données important pour « couvrir » les différents axes.
- ▶ Sans données en quantité suffisante, toutes les méthodes basées sur de l'estimation locale, comme les arbres et les méthodes d'agrégation, seront en incapacité d'estimer correctement la fonction de lien (classification supervisée et régression).

Généralités

Apprentissage supervisé



Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Le fléau de la dimension II



- Un sous-hypercube d'arrête égale à $\frac{1}{10}$ représente $\frac{1}{10}$ du volume total en dimension 1, $\frac{1}{100}$ en dimension 2. . .
- Si on souhaitait disposer de 10 données a minima sur un sous-hypercube d'arrête $\frac{1}{10}$ en dimension 10, en supposant une répartition uniforme, il faudrait disposer d'un échantillon de taille 10×10^{10} , soit 100 milliards de données.

Généralités

Apprentissage supervisé

Sur-apprentissage

Critères d'évaluation de la performance de modèles

Compléments sur la classification supervisée

Références

Plan

Apprentissage supervisé

Formalisation

Pertes et risques

Erreurs d'approximation et d'estimation

Biais et variance

Généralités

**Apprentissage
supervisé**

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Références

En guise de préambule

All models are wrong,
but some are useful

George E. P. Box



Less is more

Mies van der Rohe



Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Apprentissage supervisé

Formalisation

Pertes et risques

Erreurs d'approximation et d'estimation

Biais et variance

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

- ▶ On dispose d'un échantillon de $(X_1, \dots, X_p, Y)$:

$$d_n = (x_{i1}, \dots, x_{ip}, y_i)_{i \in \{1, \dots, n\}} \cdot$$

- ▶ $X_1, \dots, X_p$ sont appelées **covariables**, **caractéristiques** (*features*), **variables** (explicatives) ou **prédicteurs**.
- ▶ Y est appelé **variable à expliquer**, **label** ou **étiquette**.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance


Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Rappel sur les types de variables



Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Objectif

- ▶ On se place dans le cadre de la **prévision** : on souhaite prévoir y pour une nouvelle valeur x .
- ▶ Illustration sur le jeu de données MNIST (<http://yann.lecun.com/exdb/mnist/>) :

- ▶ **Modéliser** :



- ▶ **Prévoir** :

9

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

- ▶ On considèrera très souvent dans la suite que :

$$X_1, \dots, X_p \in \mathbb{R}^p .$$

- ▶ Par défaut les covariables seront considérées comme quantitatives mais on pourra traiter des variables qualitatives :
 - ▶ directement dans certaines méthode (ex : arbres),
 - ▶ à l'aide d'indicateurs sur chacune des modalités des variables qualitatives.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Régression et classification supervisée

- ▶ **Régression** : la variable Y est quantitative.
Dans la suite on considèrera que $Y \in \mathbb{R}$.
Mais il est possible de considérer plus généralement $Y \in \mathbb{R}^d$.
- ▶ **Classification supervisée** : la variable Y est qualitative.
Dans la suite on considèrera que $Y \in \{-1, 1\}$ (ou $Y \in \{0, 1\}$).
Par défaut la classification supervisée sera considérée binaire mais on sera amené à traiter des classifications supervisés avec (strictement) plus de 2 labels.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

- ▶ On suppose que (X, Y) où $X = (X_1, \dots, X_p)$ est de loi de probabilité inconnue $P_{X,Y}$ (modèle statistique non-paramétrique).
- ▶ La fonction de prévision de Y est une fonction $f : \mathcal{X} \rightarrow \mathcal{Y}$.
- ▶ On suppose que $f \in \mathcal{F}$.
- ▶ Dans la suite, de manière plus spécifique que f , on désignera la fonction de lien par :
 - ▶ Cas de la **classification supervisée** : g .
 - ▶ Cas de la **régression** : m .
- ▶ On cherche à **estimer** f par $\hat{f}$.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Apprentissage supervisé

Formalisation

Pertes et risques

Erreurs d'approximation et d'estimation

Biais et variance

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Qualité d'un estimateur

- ▶ La qualité d'un estimateur $\hat{f}$ est évaluée par le **risque** R (ou encore **erreur de généralisation**) qui :
 - ▶ permet de sélectionner un modèle,
 - ▶ fournit un indice de la confiance qu'on peut avoir en une prévision.
- ▶ Le risque est défini à partir d'une **fonction de coût** (ou encore **fonction de perte**).

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Fonctions de perte

- ▶ On appelle **fonction de perte** une fonction

$\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+$ telle que :

- ▶ $\ell(y, y) = 0$,
- ▶ $\forall y \neq y' : \ell(y, y') > 0$.

- ▶ Exemples de fonctions de perte :

- ▶ Cas de la **classification supervisée binaire** :

$$\ell(y, y') = \mathbb{1}_{y \neq y'}$$

- ▶ Cas de la **régression** :

$$\ell(y, y') = |y - y'|^q$$

avec $q \in \mathbb{R}^+$.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Risque (erreur de généralisation)

- Le **risque** (ou **erreur de généralisation**) d'un estimateur $\hat{f}$ est défini par :

$$R(\hat{f}) = \mathbb{E} \left[\ell(\hat{f}(X), Y) \right] .$$

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Oracle

- ▶ Si on connaissait $P_{X,Y}$, on pourrait déterminer la fonction de lien optimale, appelé **oracle** :

$$f^* = \arg \min_{f \in \mathcal{F}} R(f) .$$

- ▶ Quelques exemples :

- ▶ Cas de la **classification supervisée binaire** :

Si $\ell(y, y') = \mathbb{1}_{\{y \neq y'\}}$ alors :

$$g^*(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 / X = x) \geq \mathbb{P}(Y = -1 / X = x) \\ -1 & \text{sinon} \end{cases} .$$

- ▶ Cas de la **régression** :

- ▶ Si $\ell(y, y') = |y - y'|$ alors :

$$m^*(x) = \text{Med}(Y / X = x) .$$

- ▶ Si $\ell(y, y') = (y - y')^2$ alors :

$$m^*(x) = \mathbb{E}(Y / X = x) .$$

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

- L'objectif est de déterminer une estimation $\hat{f}$ de f , à partir de l'échantillon, telle que :

$$R(\hat{f}) \approx R(f^*) .$$

- En pratique, pour estimer $f \in \mathcal{F}$:
 1. On restreint $\mathcal{F}$ à $\mathcal{S}$.
 2. On considère le risque empirique R_n (et non le risque).

D'où :

$$\hat{f} = \arg \min_{f \in \mathcal{S}} R_n(f) .$$

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

- Le risque empirique est défini par :

$$R_n(\hat{f}) = \frac{1}{n} \sum_{i=1}^n \ell(\hat{f}(x_i), y_i) .$$

- C'est un estimateur de $R(\hat{f})$.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Apprentissage supervisé

Formalisation

Pertes et risques

Erreurs d'approximation et d'estimation

Biais et variance

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

**Erreurs
d'approximation et
d'estimation**

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Hypothèses de travail et erreurs induites

- Dans le cas général ($\mathcal{F}$), on cherche :

$$f^* = \arg \min_{f \in \mathcal{F}} R(f) .$$

- Dans le cas restreint ($\mathcal{S} \subset \mathcal{F}$), on cherche :

$$f_S^* = \arg \min_{f \in \mathcal{S}} R(f) .$$

- On définit l'**erreur d'approximation** et l'**erreur d'estimation** comme suit :

$$R(\hat{f}_S) - R(f^*) = \underbrace{R(f_S^*) - R(f^*)}_{\text{erreur d'approximation}} + \underbrace{R(\hat{f}_S) - R(f_S^*)}_{\text{erreur d'estimation}} .$$

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance


Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Illustration



Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

**Erreurs
d'approximation et
d'estimation**

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Apprentissage supervisé

Formalisation

Pertes et risques

Erreurs d'approximation et d'estimation

Biais et variance

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Décomposition de l'erreur quadratique I

- On considère le modèle de régression :

$$Y = f(X) + \varepsilon$$

et on estime f par $\hat{f}$.

- La **variance** de l'estimateur $\hat{f}$ est définie par :

$$\text{Var} [\hat{f}(X)] = \mathbb{E} \left[\left(\hat{f}(X) - \mathbb{E} [\hat{f}(X)] \right)^2 \right] .$$

- Le **biais** de l'estimateur $\hat{f}$ est défini par :

$$\text{Biais} (\hat{f}(X)) = \mathbb{E} [\hat{f}(X)] - f(X) .$$

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Décomposition de l'erreur quadratique II

- L'**erreur quadratique** de l'estimateur $\hat{f}$ se décompose comme suit :

$$\begin{aligned} & \mathbb{E} \left[\left(Y - \hat{f}(X) \right)^2 \right] \\ &= \mathbb{E} \left[\left(\hat{f}(X) - \mathbb{E} \left[\hat{f}(X) \right] \right)^2 \right] + \left(\mathbb{E} \left[\hat{f}(X) \right] - f(X) \right)^2 + \sigma^2 \\ &= \text{Var} \left[\hat{f}(X) \right] + \text{Biais}^2 \left(\hat{f}(X) \right) + \sigma^2 \end{aligned}$$

où σ^2 est l'erreur irréductible.

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance


Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Illustration I



Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance


Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Illustration II



En orange : $\hat{y}^{(p)1}, \dots, \hat{y}^{(p)K}$

Généralités

Apprentissage
supervisé

Formalisation

Pertes et risques

Erreurs
d'approximation et
d'estimation

Biais et variance

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Sur-apprentissage

Exemple

Problème

Palliatifs

Généralités

Apprentissage
supervisé

**Sur-
apprentissage**

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Sur-apprentissage

Exemple

Problème

Palliatifs

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple I

- ▶ On considère le modèle de régression suivante :

$$\forall x \in [0, 1] : y = \cos\left(\frac{3\pi x}{2}\right) + \varepsilon$$

où $\varepsilon \sim \mathcal{N}(0, 0.1^2)$.

- ▶ On simule :
 - ▶ $n_{train} = 30$ observations $(x_i, y_i)_{i=1, \dots, n_{train}}$ à partir desquelles on estime cette fonction de régression par régression linéaire polynomiale de degré $d \in \{1, \dots, 11\}$; on obtient les valeurs ajustées $(\hat{y}_i)_{i=1, \dots, n_{train}}$.
 - ▶ $n_{test} = 8$ observations $(x_i, y_i)_{i=1, \dots, n_{test}}$, non utilisées pour l'apprentissage (l'estimation) du modèle, pour lesquelles on obtient les prévisions $(\hat{y}_i^{(p)})_{i=1, \dots, n_{test}}$ qu'on compare aux réalisations $(y_i)_{i=1, \dots, n_{test}}$.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple II

- ▶ On évalue la qualité :
 - ▶ de l'ajustement par le RMSE (*Root Mean Squared Error*) sur l'échantillon d'apprentissage :

$$\text{RMSE}_{\text{train}} = \sqrt{\frac{1}{n_{\text{train}}} \sum_{i=1}^{n_{\text{train}}} (\hat{y}_i - y_i)^2}.$$

- ▶ de la prévision par le RMSE sur l'échantillon de test :

$$\text{RMSE}_{\text{test}} = \sqrt{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (\hat{y}_i^{(p)} - y_i)^2}.$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage


Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple III



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs


Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple IV

Régression polynômiale de degré 0 : $RMSE_{\text{train}} \approx 0.57$; $RMSE_{\text{test}} \approx 1.03$



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs


Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple V

Régression polynômiale de degré 1 : $RMSE_{\text{train}} = 0.47$; $RMSE_{\text{test}} = 0.59$



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs


Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple VI

Régression polynômiale de degré 2 : $RMSE_{\text{train}} \approx 0.2$; $RMSE_{\text{test}} \approx 0.21$



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs


Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple VII

Régression polynômiale de degré 3 : $RMSE_{\text{train}} \approx 0.12$; $RMSE_{\text{test}} \approx 0.09$



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs


Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple VIII

Régression polynômiale de degré 5 : $RMSE_{\text{train}} \approx 0.09$; $RMSE_{\text{test}} \approx 0.11$



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs


Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple IX

Régression polynômiale de degré 11 : $RMSE_{\text{train}} \approx 0.07$; $RMSE_{\text{test}} \approx 0.44$



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème


Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Impact de la complexité : exemple X



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Sur-apprentissage

Exemple

Problème

Palliatifs

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème


Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Erreur de prévision et complexité I



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème


Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Erreur de prévision et complexité II



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Caractérisation de la complexité

- ▶ Pour le **modèle linéaire** (régression linéaire ou régression logistique) : le **nombre de covariables**.
- ▶ Pour les **méthodes de régularisation** (Ridge, LASSO, Elastic Net) : **inverse(s) du(des) paramètre(s) de régularisation**.
- ▶ Pour **CART** : le **nombre de découpages**.
- ▶ Pour les **random forests** : aucun, il n'y a pas de sur-apprentissage (le temps de calcul reste néanmoins une limite).
- ▶ Pour le **gradient boosting** : le **nombre d'itérations**.
- ▶ Dans les **réseaux de neurones** : la **taille du réseau** et le **nombre d'époques**.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème


Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Erreur test, biais et variance



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plan

Sur-apprentissage

Exemple

Problème

Palliatifs

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Plusieurs stratégies

- ▶ Utilisation de **critères d'information** tels que l'AIC et le BIC (ou le C_p de Mallows) pour les **modèles linéaires** (régression linéaire et régression logistique).
- ▶ Méthodes de rééchantillonnage :
 - ▶ Les procédures sont :
 - ▶ **Apprentissage / Validation / Test** : dans le cas où on dispose de **gros échantillons**.
 - ▶ **Validation croisée** : dans le cas où on dispose d'**échantillons de taille moyenne**.
 - ▶ **Validation croisée itérée** : dans le cas où on dispose de **petits échantillons**.
 - ▶ L'échantillon de **validation** permet de calibrer les **hyperparamètres optimaux**.
 - ▶ L'échantillon **test** permet d'évaluer l'**erreur de prévision** à partir des données disponibles.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références


Apprentissage/validation/test : erreur



Hyperparamètres
optimaux



Evaluation de l'erreur



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références


Apprentissage/validation/test : prévision



Hyperparamètres optimaux



**Prévisions de
nouvelles données**



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée I

1. Diviser aléatoirement les données en K blocs (égaux ou équivalents).

Le bloc k contient n_k observations : $n_k = \frac{n}{K}$ si n est un multiple de K .

2. Pour $k \in \{1, \dots, K\}$:

- 2.1 Retirer le bloc k de la base d'apprentissage.

- 2.2 Estimer la fonction de prévision sur la base d'apprentissage.

- 2.3 Calculer un critère d'erreur de prévision sur le bloc k : CV_k (ex : MSE pour la régression).

3. Calculer le critère de validation croisée :

$$CV = \sum_{k=1}^K \frac{n_k}{n} CV_k .$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée II

- ▶ Usuellement $K = 5$ ou $K = 10$.
- ▶ Lorsque $K = n$, on parle d'estimateur « **leave one out** » (LOO)

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple

Problème



Palliatifs

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Références

Validation croisée ($K = 5$) : erreur




Evaluation de l'erreur



Hyperparamètres optimaux

Prévision de Fold 1



Généralités

Apprentissage
supervisé

Sur-
apprentissage



Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée ($K = 5$) : prévision



Généralités

Apprentissage
supervisé

Sur-
apprentissage


Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée ($K = 5$) partielle : erreur



Généralités

Apprentissage
supervisé

Sur-
apprentissage


Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée ($K = 5$) partielle : prévision



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple
Problème


Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée ($K = 5$) itérée : erreur



Généralités

Apprentissage
supervisé

Sur-
apprentissage


Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Validation croisée ($K = 5$) itérée : prévision



Généralités

Apprentissage
supervisé

Sur-
apprentissage


Exemple
Problème
Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Choix de la stratégie



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Exemple
Problème

Palliatifs

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références

Critères d'évaluation de la performance de modèles

- Classification supervisée
- Régression

Généralités

Apprentissage
supervisé

Sur-
apprentissage

**Critères
d'évaluation de
la performance
de modèles**

Classification
supervisée

Régression

Compléments sur
la classification
supervisée

Références

Plan

Critères d'évaluation de la performance de modèles

Classification supervisée

Régression

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Prévision (cas de la classification supervisée binaire)

- ▶ On procède de la manière suivante :
 - ▶ On **estime** un modèle sur l'**échantillon d'apprentissage**.
 - ▶ On utilise ce modèle estimé pour calculer les **probabilités prévues** $\hat{\mathbb{P}}(Y = 1 / X = x_i)$ sur l'**échantillon test**.
 - ▶ On en déduit les **prévisions** $\hat{y}_i^{(p)}$ sur l'**échantillon test** :

$$\hat{y}_i^{(p)} = \begin{cases} 1 & \text{si } \hat{\mathbb{P}}(Y = 1 / X = x_i) \geq s \\ 0 \text{ (ou -1)} & \text{sinon} \end{cases}$$

où s est un seuil de décision fixé par l'utilisateur (usuellement $s = \frac{1}{2}$).

- ▶ S'il existe de nombreux critères de qualité possibles, il faut choisir celui(ceux) qui répond(ent) au mieux à la problématique métier.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Matrice de confusion

- Dans le cas de la classification supervisée binaire, la **matrice de confusion** vaut (avec les notations TP et TN pour True Positive et True negative) :

		Prévision	
		1	0 (ou -1)
Vérité	1	Vrai Positif (TP)	Faux Négatif (FN)
	0 (ou -1)	Faux Positif (FP)	Vrai Négatif (TN)

- Dans le cas de la classification supervisée non-binaire, on peut établir la matrice de confusion, avec autant de lignes et de colonnes que de classes, et en déduire les nombres TP, FP, TN et FN.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

- ▶ On considère usuellement :
 - ▶ L'exactitude.
 - ▶ La spécificité.
 - ▶ La précision.
 - ▶ La sensibilité
 - ▶ Le F_1 .
 - ▶ L'AUC.
- ▶ Ces indicateurs prennent leurs valeurs sur $[0, 1]$: plus ils sont proches de 1, meilleur est le modèle.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Exactitude (et erreur de classification) et spécificité

- L'**exactitude** (*accuracy*) vaut :

$$\text{exactitude} = \frac{TP + TN}{TP + FP + TN + FN} .$$

Notons que l'erreur de classification (*classification error*) vaut :

$$\text{erreur} = \frac{FP + FN}{TP + FP + TN + FN} = 1 - \text{exactitude} .$$

- La **spécificité** (*specificity*), le taux de négatifs classés négatifs (« taux de vrais négatifs » noté **TNR** : True Negative Rate), vaut :

$$\text{spécificité} = \frac{TN}{FP + TN} .$$

L'**anti-spécificité** est le taux de négatifs classés positifs (« taux de faux positifs » noté **FPR** : False Positive Rate).

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Précision, sensibilité et F_1

- La **précision** (*precision*), ou valeur prédictive positive, vaut :

$$\text{précision} = \frac{TP}{TP + FP} .$$

- La **sensibilité** (*sensitivity*), ou rappel (*recall*), est le taux de positifs classés positifs (« taux vrais positifs », noté **TPR** : *True Positive Rate*) :

$$\text{sensibilité} = \frac{TP}{TP + FN} .$$

- Le score **F_1** est la moyenne harmonique de la précision et de la sensibilité :

$$\begin{aligned} F_1 &= \frac{2}{\frac{1}{\text{précision}} + \frac{1}{\text{sensibilité}}} \\ &= 2 \frac{\text{précision} \cdot \text{sensibilité}}{\text{précision} + \text{sensibilité}} . \end{aligned}$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Courbe ROC I

- ▶ La courbe **ROC** (Receiver Operating Characteristic) représente la sensibilité (taux de vrais positifs : TPR) en fonction de l'anti-spécificité (taux de faux positifs : FPR) pour différents seuils de décision s :

$$\hat{y}_i^{(p)} = \begin{cases} 1 & \text{si } \hat{\mathbb{P}}(Y = 1 / X = x_i) \geq s \\ 0 \text{ (ou -1)} & \text{sinon} \end{cases} .$$

- ▶ Plus le seuil s est important :
 - ▶ plus le taux de vrais positifs est important,
 - ▶ moins le taux de faux positifs est important.
- ▶ La courbe ROC est croissante et au-dessus de la première bissectrice (correspondant à une prédiction de type « tirage au sort »).
- ▶ La prédiction « optimale » fournirait une courbe ROC égale à 0 pour $s = 0$ et égale à 1 pour $s \in]0, 1]$.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Courbe ROC II



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

AUC I



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

- ▶ L'aire sous la courbe ROC, l'**AUC** (Area Under the ROC), est une mesure de la qualité de la classification et varie entre :
 - ▶ $AUC = \frac{1}{2}$: le pire des cas (prédiction de type « tirage au sort »),
 - ▶ $AUC = 1$: le meilleur des cas (prédiction « optimale »).

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Exemple ROC/AUC I

Individus	Label	Probabilité d'être positif
1	0	0.10
2	0	0.15
3	1	0.20
4	0	0.30
5	0	0.35
6	1	0.35
7	0	0.40
8	1	0.55
9	1	0.60
10	1	0.75
11	1	0.75
12	0	0.80
13	1	0.90
14	1	0.95

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Exemple ROC/AUC II

Individus	Label	Probabilité d'être positif	Label prévu (avec $s = 0.25$)
1	0	0.10	0
2	0	0.15	0
3	1	0.20	0
4	0	0.30	1
5	0	0.35	1
6	1	0.35	1
7	0	0.40	1
8	1	0.55	1
9	1	0.60	1
10	1	0.75	1
11	1	0.75	1
12	0	0.80	1
13	1	0.90	1
14	1	0.95	1

$$P = 8, N = 6,$$

$$FP = 4, FPR = \frac{FP}{N} = \frac{4}{6},$$

$$TP = 7, TPR = \frac{TP}{P} = \frac{7}{8}.$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Exemple ROC/AUC III

Seuil	Taux de vrais positifs (TP)	Taux de faux positifs (FP)
0.00	$\frac{8}{8}$	$\frac{6}{6}$
0.10	$\frac{8}{8}$	$\frac{5}{6}$
0.15	$\frac{8}{8}$	$\frac{4}{6}$
0.20	$\frac{7}{8}$	$\frac{4}{6}$
0.30	$\frac{7}{8}$	$\frac{3}{6}$
0.35	$\frac{6}{8}$	$\frac{2}{6}$
0.40	$\frac{6}{8}$	$\frac{1}{6}$
0.55	$\frac{5}{8}$	$\frac{1}{6}$
0.60	$\frac{4}{8}$	$\frac{1}{6}$
0.75	$\frac{2}{8}$	$\frac{1}{6}$
0.80	$\frac{2}{8}$	$\frac{0}{6}$
0.90	$\frac{1}{8}$	$\frac{0}{6}$
0.95	$\frac{0}{8}$	$\frac{0}{6}$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Exemple ROC/AUC IV



$$\text{AUC} = \frac{1}{6} \frac{1}{4} + \frac{1}{6} \frac{3}{4} + \frac{1}{2} \frac{1}{6} \left(\frac{6}{8} + \frac{7}{8} \right) + \frac{1}{6} \frac{7}{8} + \frac{1}{3} = \frac{75}{96} \simeq 0.78.$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Classification
supervisée**

Régression

Compléments sur
la classification
supervisée

Références

Plan

Critères d'évaluation de la performance de modèles

Classification supervisée

Régression

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Classification
supervisée

Régression

Compléments sur
la classification
supervisée

Références

- ▶ On procède de la manière suivante :
 - ▶ On **estime** un modèle sur l'**échantillon d'apprentissage**.
 - ▶ On utilise ce modèle estimé pour calculer les **prévisions** $\hat{y}_i^{(p)}$ sur l'**échantillon test**.
- ▶ Concernant les critères d'erreur :
 - ▶ S'il existe de nombreux critères possibles, il faut choisir celui(ceux) qui répond(ent) au mieux à la problématique métier.
 - ▶ Les **écarts quadratiques** sont classiquement utilisés à l'aide des **RMSE** et **nRMSE** (ils correspondent souvent au critère qui a été optimisé).
 - ▶ On peut utiliser des **écarts absolus** à l'aide du **MAE** ou absolus relatifs à l'aide du **MAPE** (à éviter si Y prend des valeurs proches de 0).

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Classification
supervisée

Régression

Compléments sur
la classification
supervisée

Références

MSE, RMSE et nRMSE

- ▶ Le **MSE** (*Mean Squared Error* : erreur quadratique moyenne) vaut :

$$\text{MSE} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \left(\hat{y}_i^{(p)} - y_i \right)^2 .$$

- ▶ Le **RMSE** (*Root Mean Squared Error* : racine carrée de l'erreur quadratique moyenne) vaut :

$$\text{RMSE} = \sqrt{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \left(\hat{y}_i^{(p)} - y_i \right)^2} .$$

- ▶ Le **nRMSE** (*normalized RMSE* : RMSE normalisé) vaut :

$$\text{nRMSE} = \frac{\text{RMSE}}{\frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \hat{y}_i^{(p)}} .$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Classification
supervisée

Régression

Compléments sur
la classification
supervisée

Références

- ▶ Le **MAE** (*Mean Absolute Error* : erreur absolue moyenne) vaut :

$$\text{MAE} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \left| \hat{y}_i^{(p)} - y_i \right| .$$

- ▶ Le **MAPE** (*Mean Absolute Percent Error* : erreur absolue moyenne relative) vaut :

$$\text{MAPE} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \left| \frac{\hat{y}_i^{(p)} - y_i}{y_i} \right| \times 100 .$$

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Classification
supervisée

Régression

Compléments sur
la classification
supervisée

Références

Compléments sur la classification supervisée

- Classification supervisée non-binaire
- Données déséquilibrées

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

**Compléments sur
la classification
supervisée**

Classification
supervisée non-binaire
Données déséquilibrées

Références

Compléments sur la classification supervisée

Classification supervisée non-binaire

Données déséquilibrées

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

**Classification
supervisée non-binaire**

Données déséquilibrées

Références

Classification supervisée non-binaire

- Pour les méthodes de classification supervisée ne traitant que le cas binaire (ex : SVM), il existe différentes stratégies dans le cas où on a $K > 2$ classes, parmi lesquelles :
 - Stratégie « une contre toutes » **OvR** (One vs Rest)
 1. On effectue les K classifications supervisées binaires $Y = k$ contre $Y \neq k$ pour $k \in \{1, \dots, K\}$.
 2. On affecte à une observation la classe qui a la probabilité la plus élevée parmi ces K classifications supervisées binaires.
 - Stratégie « une contre une » **OvO** (One vs One)
 1. On effectue les $\binom{K}{2}$ classifications supervisées binaires $Y = k$ contre $Y = k'$ pour $(k, k') \in \{1, \dots, K\}^2$ et $k \neq k'$.
 2. On affecte à une observation la classe majoritaire parmi ces $\binom{K}{2}$ classifications supervisées binaires.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire
Données déséquilibrées

Références

Compléments sur la classification supervisée

Classification supervisée non-binaire

Données déséquilibrées

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

Problématique

- ▶ Des **données déséquilibrées** peuvent conduire à une évaluation fallacieuse des modèles.
- ▶ La notion de déséquilibre n'est pas définie formellement mais un ratio de 1 à 10 entre 2 classes est un ordre de grandeur communément considéré.
- ▶ Le déséquilibre sera plus fortement ressenti lorsque la taille de l'échantillon est petite.
- ▶ En tout premier lieu, il faut évaluer l'opportunité de disposer de nouvelles données et toujours adopter les critères de mesure les plus adéquats pour la qualité des modèles.
- ▶ On utilise classiquement des **méthodes de rééchantillonnage**.
- ▶ On utilise ces algorithmes **uniquement sur l'échantillon d'apprentissage**, pas sur ceux de validation ou de test.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

Sur-échantillonnage

- ▶ Il est possible de procéder à du **sur-échantillonnage** (*oversampling*) :
 - ▶ Méthode naïve : dupliquer aléatoirement des observations de la classe minoritaire jusqu'à l'obtention du ratio classe minoritaire-classe majoritaire souhaité.
 - ▶ Un des algorithmes les plus utilisés est **SMOTE** (Synthetic Minority Over-sampling TEchnique) pour des covariables quantitatives. Pour des covariables qualitatives, il existe une alternative : SMOTENC (SMOTE Nominal Continuous).
(Chawla et collab., 2002)
 - ▶ Il existe des variantes à SMOTE comme **BorderSMOTE** et **ADASYN** (ADAPtative SYNthetic) qui permettent de pallier la génération d'observations « dangereuses », près des frontières entre les classes. ADASYN prend en considération la densité des observations de la classe minoritaire.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE I

- ▶ Pour chaque individu i de la classe minoritaire :
 1. Déterminer ses k plus proches voisins (k fixé, inférieur au nombre d'observations de la classe minoritaire).
 2. Tirer au sort un de ses k plus proches voisins i' .
 3. Calculer pour toutes les covariables les écarts entre les individus i et i' (dans le cas où les covariables sont quantitatives).
 4. Multiplier ces écarts par un nombre aléatoire sur $[0, 1]$.
 5. Ajouter ces valeurs aux covariables de l'individu i afin de créer un nouvel individu de la classe minoritaire.
- ▶ Répéter cette opération autant de fois que nécessaire pour obtenir le ratio classe minoritaire-classe majoritaire souhaité (l'algorithme originel inclut en sus un sous-échantillonnage aléatoire parmi les observations de la classe majoritaire).

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE II



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE III



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE IV



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE V



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE VI



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles


Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

SMOTE VII



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

- ▶ Il est possible de procéder à du **sous-échantillonnage** (*undersampling*) :
 - ▶ Méthode naïve : supprimer aléatoirement des observations de la classe majoritaire jusqu'à l'obtention d'un ratio classe minoritaire- classe majoritaire acceptable.
 - ▶ Les algorithmes **Tomek link** et **NearMiss** visent à supprimer les observations de la classe majoritaire proches des observations de la classe minoritaire.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

- ▶ On peut utiliser le **cost-sensitive learning**, comme le gradient boosting, qui désigne les méthodes d'apprentissage prenant en compte le coût d'une mauvaise classification. Il est ainsi possible d'attribuer des poids accrus pour les observations issues de la classe minoritaire.
- ▶ On peut également utiliser les techniques d'**ensemble learning** (méthodes d'agrégation) : constituer plusieurs échantillons équilibrés à partir des mêmes données de la classe minoritaire et agréger les résultats obtenus.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles



Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

Références I



Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Classification
supervisée non-binaire

Données déséquilibrées

Références

Références II

- Chawla, N. V., K. W. Bowyer, L. O. Hall et W. P. Kegelmeyer. 2002, «Smote : Synthetic minority over-sampling technique», *Journal of Artificial Intelligence Research*, vol. 16, p. 321—357.
- Hastie, T., R. Tibshirani et J. H. Friedman. 2009, *The elements of statistical learning. Data Mining, inference, and prediction*, 2^e éd., Springer Series in Statistics, Springer.
- James, G., D. Witten, T. Hastie et R. Tibshirani. 2021, *An introduction to statistical learning with applications in R*, 2^e éd., Springer Texts in Statistics, Springer.
- James, G., D. Witten, T. Hastie, R. Tibshirani et J. Taylor. 2023, *An introduction to statistical learning with applications in Python*, Springer Texts in Statistics, Springer.

Généralités

Apprentissage
supervisé

Sur-
apprentissage

Critères
d'évaluation de
la performance
de modèles

Compléments sur
la classification
supervisée

Références